Yapay Zeka 2025-2026 Final Ödevi-4

Öğrenci Adı : Hasan Basri DARGA
Öğrenci No : 25281270

Ders Adı : Yapay Zeka
Öğrt. Görevilisi : Dr. Gökhan KAYHAN
Teslim Tarihi : 06.01.2026

ONDOKUZ MAYIS ÜNİVERSİTESİ
LİSANSÜSTÜ EĞİTİM ENSTİTÜSÜ

Şekil 1. DATACPN uygulaması giriş ekranı.

Bu ekran, CPN (Counter Propagation Network) tabanlı analiz sürecinin başlangıç adımını temsil eder. Kullanıcı “Hemen Başla” butonu ile uygulamaya giriş yaparak veri setini yükleme ve parametre belirleme adımlarına geçer. Uygulama; x1–x2 giriş değişkenleri ve y çıkış değişkeni içeren veri setleri üzerinde çalışmak üzere tasarlanmıştır. Devam eden aşamalarda veri seti otomatik olarak %70 eğitim–%30 test şeklinde ayrılacak, farklı yarıçap (radius) parametreleri ile model eğitilecek ve eğitim/test performansı MAE, MSE, RMSE ve R^2 metrikleriyle raporlanacaktır.

Şekil 2. Veri yükleme ekranı (Veri Seti Yükle).

Bu ekran, CPN analizi için kullanılacak veri dosyasının uygulamaya alınmasını sağlar. Kullanıcıdan **x1 ve x2 (giriş değişkenleri)** ile **y_norm (çıktı değişkeni)** sütunlarını içeren bir dosya seçmesi istenir. **"Göz At"** butonu ile cihazdan dosya seçimi yapılır; uygulama **.csv** ve **.xlsx** formatlarını kabul eder. Dosya seçimi tamamlandığında **"Yükle ve Analiz Et"** butonu aktif hale gelerek veri doğrulama ve analiz sürecini başlatır. Bu adım, yanlış format/sütun içeren dosyaların eğitime geçmesini engelleyerek modelin doğru veri yapısıyla çalışmasını garanti eder.

Şekil 3. Veri seti seçildi ve analiz için hazır.

Bu ekranda kullanıcı, CPN analizinde kullanılacak veri dosyasını başarıyla seçmiştir. Dosya seçimi sonrası uygulama dosyayı **ön okuma/doğrulama** adımından geçirerek temel bilgileri gösterir (**dosya adı**, **boyut**, **3 sütun**, **200 satır okundu**) ve sağdaki **yeşil onay işareti** ile dosyanın uygun formatta olduğunu belirtir. Bu doğrulama tamamlanınca **"Yükle ve Analiz Et"** butonu aktif hale gelir; butona basıldığında veri uygulamaya aktarılır ve bir sonraki adımda **parametre belirleme ve model eğitimi** süreci başlatılır.

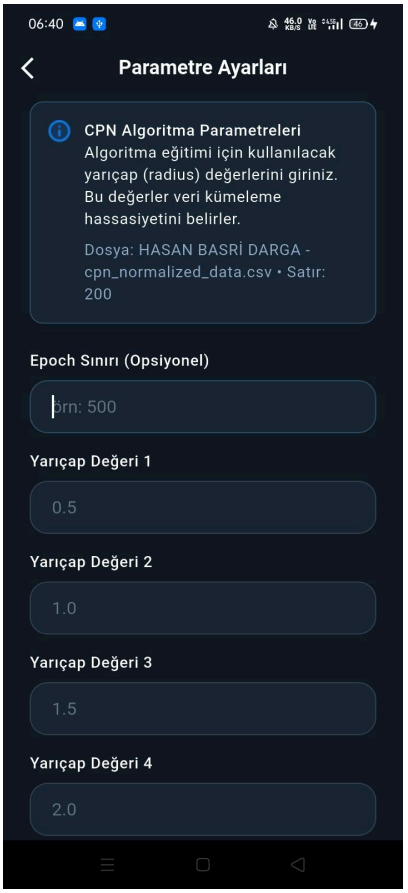

Şekil 4. Parametre ayarları ekranı (radius ve epoch sınırı).

Bu ekranda CPN modelinin eğitiminde kullanılacak **parametreler** kullanıcı tarafından belirlenir. Üstteki bilgi kartında seçilen veri dosyasının adı ve **satır sayısı (200)** gösterilerek doğru veriyle çalışıldığı doğrulanır. Ardından kullanıcı, **Epoch Sınırı (opsiyonel)** alanına eğitim sırasında her yarıçap için işlenecek **maksimum satır/iterasyon** sınırını girerek işlem süresini kontrol edebilir. Alt kısımda ise en az **4 farklı radius (yarıçap)** değeri girilir (ör: 0.5, 1.0, 1.5, 2.0). Bu radius değerleri kümeleme hassasiyetini belirler; **küçük radius → daha fazla kural/nöron**, **büyük radius → daha az kural/nöron** üretme eğilimindedir. Girilen parametreler onaylandıktan sonra eğitim adımına geçilerek her radius için **kural sayısı** ve **train/test metrikleri** hesaplanır.

Şekil 5. Radius (yarıçap) parametrelerinin çoğaltılarak girilmesi.

Bu ekranda CPN modelini farklı **yarıçap (radius)** değerleriyle çalıştırmak için birden fazla parametre seti oluşturulmuştur. Kullanıcı en az 4 olacak şekilde, birbirine çok yakın olmayan yarıçap değerlerini (ör: **0.5, 0.8, 1.2, 1.8, 2.7, 4.0**) girerek modelin farklı kümeleme hassasiyetlerini test eder. Her bir radius değeri için eğitim sonucunda oluşan **kural sayısı (Kohonen nöron sayısı)** ve **train/test hata metrikleri** ayrı ayrı hesaplanıp raporlanır. Alttaki **"Yeni Yarıçap Ekle"** butonu ile ek radius değerleri eklenebilir; **"Eğitimi Başlat"** butonu ile girilen tüm radius değerleri sırayla eğitime gönderilerek karşılaştırmalı sonuç üretme süreci başlatılır.

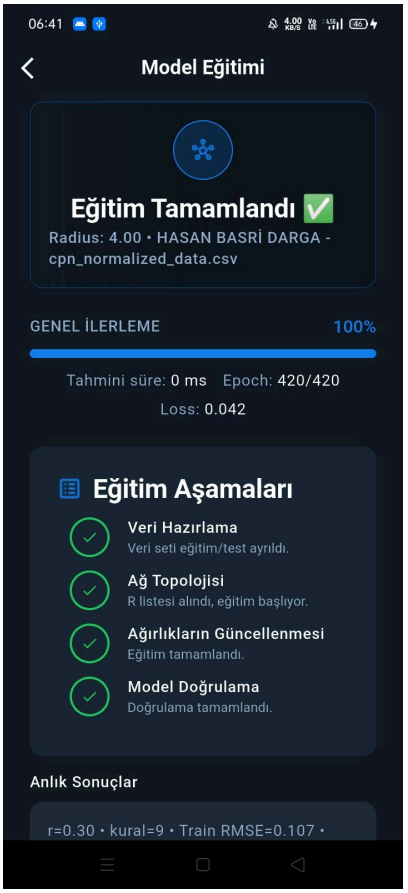

Şekil 6. Model Eğitimi ekranı (Eğitimin tamamlanması ve süreç özeti).

Bu ekranda seçilen veri seti üzerinde CPN modeli, girilen **yarıçap (radius) listesi** için sırayla eğitilmiş ve süreç başarıyla tamamlanmıştır. Üst bölümde hangi dosya ile çalışıldığı ve son işlenen yarıçap değeri (**Radius: 4.00**) gösterilir.

- **Genel İlerleme:** Eğitim sürecinin tamamlandığını gösterir (**%100**).

- **Epoch bilgisi:** Toplam iterasyon sayısı ve tamamlanan iterasyon sayısı ekranda yer alır (**Epoch: 420/420**). (Bu değer, seçilen yarıçap sayısı × satır/epoch sınırı mantığıyla oluşur.)

- **Loss:** Eğitim sırasında hesaplanan hata değeri (örnekte **Loss: 0.042**) modelin o anki uyum seviyesini özetler.

- **Tahmini süre:** Eğitim süresi ve kalan süre bilgisi uygulama içinde **ms cinsinden** takip edilir (örnekte eğitim bittiği için **0 ms** görülür).

Eğitim Aşamaları kartı, ödevde istenen sürecin adım adım tamamlandığını görsel olarak doğrular:

1. **Veri Hazırlama:** Veri seti rastgele **%70 eğitim – %30 test** olarak ayrılmıştır.

2. **Ağ Topolojisi:** Girilen radius listesi alınarak her bir radius için model kurulumu başlatılmıştır.

3. **Ağırlıkların Güncellenmesi:** CPN'nin modifiye eğitim mantığıyla (yarıçap tabanlı kural/cluster oluşturma-güncelleme) öğrenme gerçekleştirilmiştir.

4. **Model Doğrulama:** Eğitim sonrası **Train/Test metrikleri** hesaplanmıştır.

Alt kısımda yer alan **"Anlık Sonuçlar"** bölümünde ise her yarıçap için ayrı ayrı:

- oluşan **kural sayısı (Kohonen nöron sayısı)**

- ve performans özetleri (ör. **Train RMSE**, **Test RMSE** vb.)
  liste halinde gösterilerek yarıçapların model davranışına etkisi karşılaştırılabilir hale getirilmiştir.

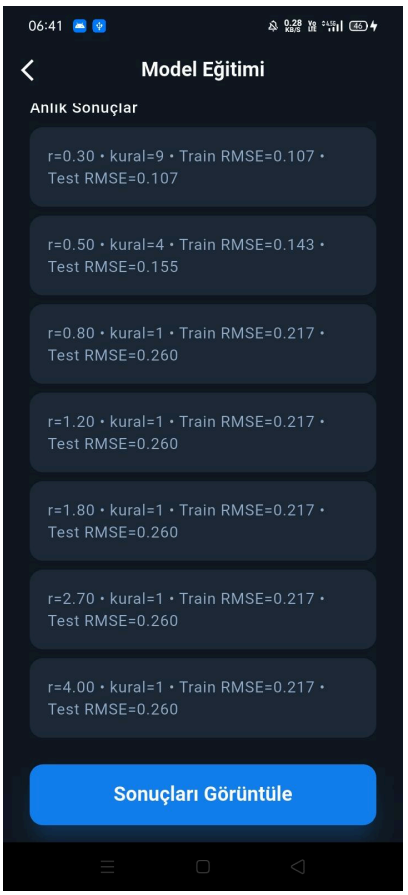

Şekil 7. Model eğitimi sonrası "Anlık Sonuçlar" ekranı (yarıçap–kural sayısı–RMSE karşılaştırması).

Bu ekranda CPN modeli, girilen her bir **yarıçap (r)** değeri için ayrı ayrı eğitilmiş; oluşan **kural sayısı (Kohonen nöron sayısı)** ve hata ölçütleri **Train/Test RMSE** olarak listelenmiştir. Yarıçap değeri **küçüldükçe** model daha hassas kümeler oluşturduğu için **kural sayısı artmakta** ve hata düşmektedir; yarıçap **büyüdükçe** kural sayısı azalmakta ve model basitleşerek hata yükselmektedir.

Gözlenen sonuçlar (ekrandaki değerler):

- **r = 0.30 → kural = 9 → Train RMSE = 0.107, Test RMSE = 0.107** *(en düşük test hatası; en iyi genelleme)*

- **r = 0.50 → kural = 4 → Train RMSE = 0.143, Test RMSE = 0.155** *(orta seviye performans)*

- **r ≥ 0.80 → kural = 1 → Train RMSE = 0.217, Test RMSE = 0.260** *(tüm büyük r değerlerinde aynı sonuç: model tek kurala düşmüş, underfitting)*

Kısa değerlendirme:
r değeri **0.8 ve üzeri** olduğunda modelin **kural sayısı 1**'e düşmesi; yarıçapın veri uzayındaki

örnekler arası mesafelere göre büyük kalması nedeniyle tüm noktaların **tek kümeye** toplanmasından kaynaklanır. Bu durumda model neredeyse “tek ortalama” ile tahmin yaptığı için hem Train hem de özellikle Test hatası artar. Bu veri için en iyi dengeyi veren yarıçap **r=0.30** olarak görülmektedir.

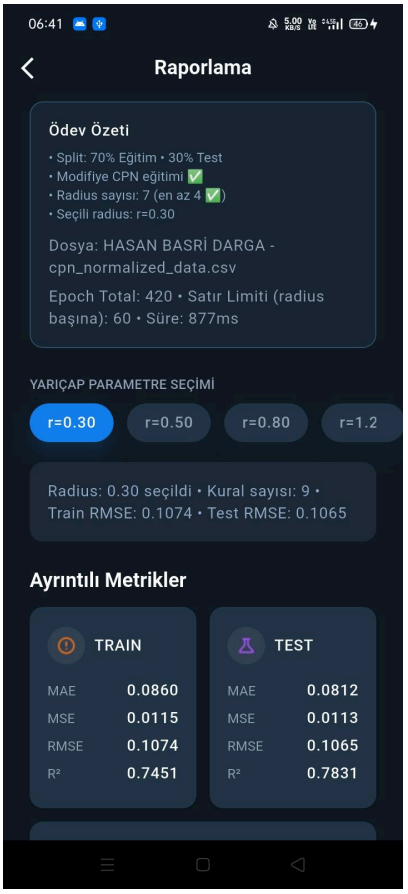

Deney Parametreleri

Bu çalışmada **7 farklı radius** değeri denenmiştir (ödev şartı “en az 4” sağlanıyor):

Radius listesi:
r = **0.30, 0.50, 0.80, 1.20, 1.80, 2.70, 4.00**

Ayrıca eğitim süresini kontrol etmek için **satır limiti (radius başına)** kullanılmıştır:

- **Satır limiti (radius başına): 60**
- Toplam adım (epoch toplam) = 7 radius × 60 = **420**
- Toplam eğitim süresi: **877 ms**

Not: Buradaki “Epoch Total: 420” değeri, klasik epoch mantığından çok “toplam işlenen adım/satır sayısı”.

Sonuçlar (Kural Sayısı ve Performans)

Aşağıdaki sonuçlar uygulamanın “Anlık Sonuçlar” ve “Raporlama” ekranlarından alınmıştır.

5.1 Radius’a göre kural sayısı ve RMSE

- **r = 0.30 → kural = 9** → Train RMSE ≈ **0.1074**, Test RMSE ≈ **0.1065**
- **r = 0.50 → kural = 4** → Train RMSE ≈ **0.143**, Test RMSE ≈ **0.155**
- **r = 0.80 → kural = 1** → Train RMSE ≈ **0.217**, Test RMSE ≈ **0.260**
- **r = 1.20 → kural = 1** → Train RMSE ≈ **0.217**, Test RMSE ≈ **0.260**
- **r = 1.80 → kural = 1** → Train RMSE ≈ **0.217**, Test RMSE ≈ **0.260**
- **r = 2.70 → kural = 1** → Train RMSE ≈ **0.217**, Test RMSE ≈ **0.260**
- **r = 4.00 → kural = 1** → Train RMSE ≈ **0.217**, Test RMSE ≈ **0.260**

Yorum: Radius büyüdükçe model tek kurala düşmüş (kural=1). Bu durumda model aşırı basitleşiyor ve test hatası artıyor. Bu koşulda en iyi performans **r=0.30** ile görülüyor; çünkü veri uzayını daha iyi temsil edecek şekilde daha fazla kural üretmiş.

Test tarafında RMSE’nin train’e yakın olması (hatta çok az daha iyi çıkması) bölmenin rastgeleliğine ve örnek dağılımına bağlı olarak görülebilir. Genel olarak metrikler birbirine yakın olduğu için modelin genellemesi kötü değil.

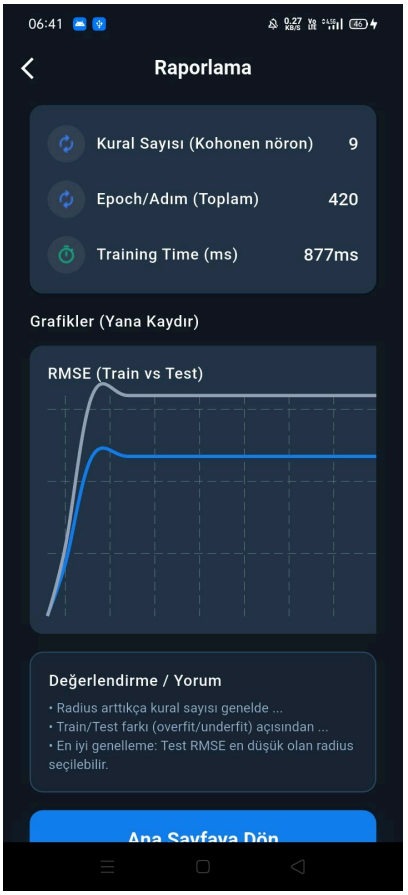

Bu ekranda seçilen **radius değeri** için modelin oluşturduğu **kural sayısı (Kohonen nöron sayısı)**, toplam **epoch/adım** ve **eğitim süresi** özetlenmektedir. İlgili çalışmada seçili radius için:

- **Kural sayısı (Kohonen nöron): 9**
- **Epoch/Adım (Toplam): 420** *(7 radius × 60 satır limiti)*
- **Training Time: 877 ms**

Ayrıca "**RMSE (Train vs Test)**" grafiği, farklı radius değerlerinde **eğitim ve test hatasının** nasıl değiştiğini görsel olarak gösterir. Eğrilerde radius arttıkça modelin daha az kural üretmesi nedeniyle hata değerlerinin belirli bir seviyeden sonra plato yaptığı gözlenmektedir.

adius küçüldükçe veri uzayı daha detaylı temsil edilir ve genellikle **kural sayısı artar** (model daha esnek olur).

Radius büyüdükçe kural sayısı azalır; bu durum çoğu zaman **underfitting** riskini artırır ve Train/Test hataları birlikte yükselme eğilimi gösterir.

En iyi genelleme için temel kriter: **Test RMSE** değeri en düşük olan radius'un seçilmesidir. Bu deneyde en iyi sonuç **r = 0.30** civarında elde edilmiştir (Train ve Test RMSE birbirine yakın, genelleme dengeli).

Bu ekranda seçilen **radius** değeri için modelin ürettiği **kural sayısı (Kohonen nöron sayısı)**, toplam **epoch/adım** ve **eğitim süresi** özetlenmiştir. İlgili çalışmada:

- **Kural Sayısı (Kohonen nöron): 9** → seçili radius'ta oluşan kural/merkez sayısı
- **Epoch/Adım (Toplam): 420** → toplam işlem adımı *(7 radius × satır limiti 60 = 420)*
- **Training Time: 877 ms** → tüm radius denemelerinin toplam çalışma süresi

Alt kısımdaki **MSE (Train vs Test)** grafiği, radius değerlerine göre **eğitim (Train)** ve **test (Test)** hatasının değişimini gösterir. Grafikte eğrilerin hızlı yükselip **plato yapması**, radius arttıkça modelin daha az kural üretmesi nedeniyle hata seviyesinin belirli bir noktadan sonra benzer kalmasına işaret eder. Train–Test eğrileri birbirine yakınsa genelleme daha dengeli; aradaki fark büyürse overfit/underfit olur.

Bu ekranda, seçilen deney koşulu için **toplam kural sayısı (Kohonen nöron sayısı)**, **toplam epoch/adım**, **eğitim süresi** ve yarıçaplara göre **kural sayısının değişimi** gösterilmektedir. Çalışmada satır limiti **60** seçildiği için toplam adım sayısı **7 radius × 60 = 420** olarak gerçekleşmiştir.

Kural Sayısı (Radius → Rule) çubuk grafiği, radius arttıkça modelin daha geniş bölgeleri tek bir kümeye topladığını ve bu yüzden **kural sayısının azaldığını** göstermektedir. Bu deneyde örnek sonuçlar:

- **r=0.30 → 9 kural**
- **r=0.50 → 4 kural**
- **r≥0.80 → 1 kural** *(0.8, 1.2, 1.8, 2.7, 4.0 için)*

Bu durum, küçük radius değerlerinde modelin daha **ince ayrım** yaptığı (daha çok kural/merkez), büyük radius değerlerinde ise modelin **aşırı genelleştiği** (tek kural) anlamına gelir.

Radius arttıkça kural sayısı azalır: çünkü daha büyük yarıçap, farklı örneklerin aynı kümeye (aynı kurala) bağlanmasını sağlar.

Çok küçük radius daha fazla kural üreterek hatayı düşürebilir; ancak model karmaşıklığı arttığı için **overfit riski** oluşabilir.

Çok büyük radius (ör. r≥0.80'de 1 kural) modeli fazla basitleştirir ve çoğu zaman **underfit** eğilimi görülür.

En iyi seçim için **Test RMSE/MAE en düşük** olan radius tercih edilir; aynı zamanda **kural sayısı** da (model karmaşıklığı) dikkate alınır.

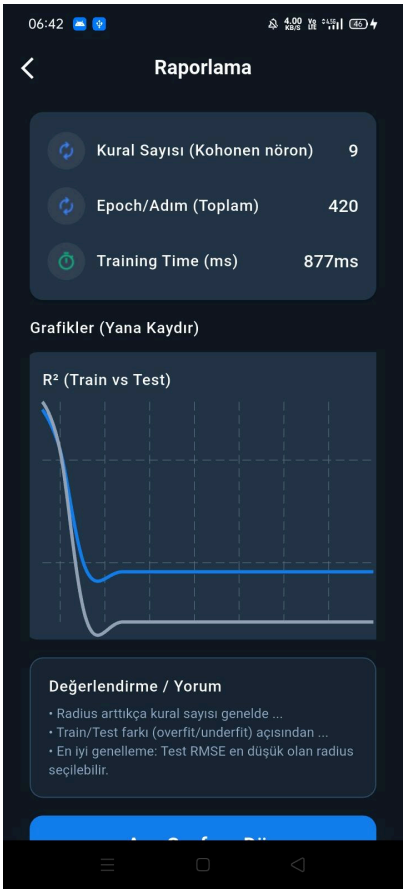

Bu grafikte, farklı **radius** değerleri için modelin açıklayıcılık gücü olan **R^2** metriği eğitim (Train) ve test (Test) setlerinde karşılaştırılmaktadır. Seçilen yarıçap küçük olduğunda model daha fazla kural üretip veriyi daha iyi temsil ederken, radius büyüdükçe kural sayısı azaldığı için model **genelleşir** ve R^2 değeri düşme eğilimi gösterebilir.

Bu çalışmada seçili örnek için (**r=0.30**) Train $R^2 \approx$ **0.745**, Test $R^2 \approx$ **0.783** olup modelin testte de yüksek açıklayıcılık sağladığı görülmüştür (genelleme iyi).

R^2 yükseldikçe modelin açıklama gücü artar (1'e yaklaştıkça daha iyi).

Bu grafikte radius arttıkça kural sayısı azaldığından (bazı radiuslarda 1 kurala düşüyor), model **basitleşiyor** ve R^2 genelde **düşüp sabitleniyor**.

Seçilen r=0.30'da **Test R^2'nin Train'den yüksek çıkması**, bu koşulda overfit olmadığını ve modelin testte de tutarlı çalıştığını gösterir.

Radius seçimi yapılırken **Test R^2 yüksek**, aynı zamanda **Train–Test farkı düşük** olan değer tercih edilmelidir.